向量点积延迟与加速分析报告

252 轮香山完整处理器硬件计时实验已全部通过校验。实测数据显示：在每轮循环展开 16 个独立点积的吞吐场景下，自定义 vdot.vv 指令的平均耗时降至 1.064012 周期/点积，而同等测试条件下的标准 RVV 指令组合为 5.022429 周期/点积，对应硬件周期比达 4.720 倍；在 32×32×32 通用矩阵乘法场景下，采用四列共享装载 + 向量寄存器累加优化方案的总耗时为 23032 周期，较逐次直接取回方案的 31984 周期进一步缩减 28.0%。

1 测量对象与完成情况

本报告对应官方阶段三第 3.2 项标准向量组合参考实现及第 3.3 项延迟加速分析交付要求。文中引用的工程文件路径均以相关证明材料根目录为起点，所有性能分析均基于实测产出的通用矩阵接口 GEMM 与独立点积展开度基准测试数据。被测处理器采用香山 KunminghuV2Config 单核配置、向量寄存器宽度 VLEN=128，且全套仿真运行期间全程开启 NEMU 在线同步比对。

性能评测专项内容	测试程序数	单程序重复轮次	校验通过总轮次
通用矩阵乘法接口	12	3	36
独立点积展开数量与原址依赖链	72	3	216
总计	84	3	252

2 标准 RVV 组合实现

在算术语义上，标准 RVV 参考方案与自定义 vdot.vv 指令严格对齐：均截取两个源向量寄存器的低 8 个有符号 INT8 元素执行点积，将精确求和结果写入目标寄存器的低 32 位，并将高 96 位强制清零。在标准 RVV 测速循环中，每次点积运算需依次执行以下 5 条指令：

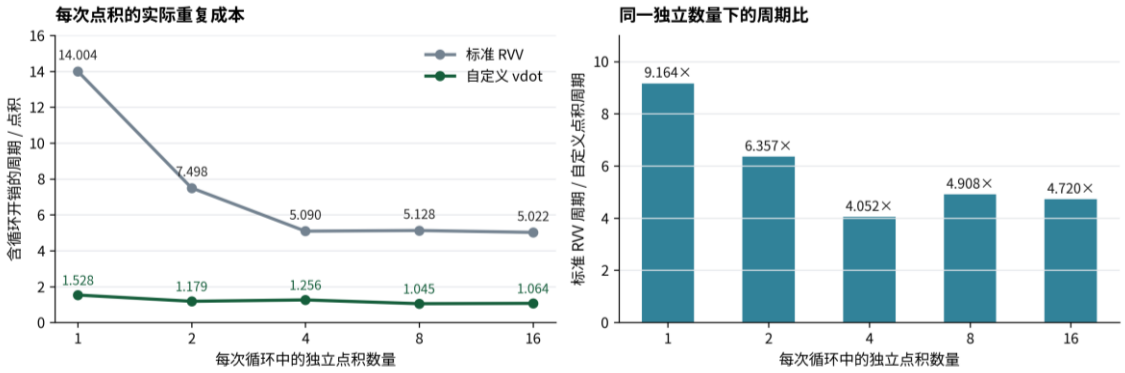
```
vwmul.vv v16,v31,v30
vsetivli zero,8,e16,m1,tu,mu
vmv.v.i v0,0
vwredsum.vs v0,v16,v0
vsetivli zero,8,e8,m1,ta,ma
```

具体而言，首条有符号加宽乘法指令 vwmul.vv 将 8 对 INT8 输入相乘并扩宽为 16 位中间乘积；随后切换至 e16 模式，通过 vmv.v.i 将目标寄存器 v0 整体清零，并调用加宽归约指令 vwredsum.vs 将 8 项 16 位乘积扩宽累加为 32 位总和写入 v0 低 32 位；末尾第 5 条 vsetivli 指令负责将向量环境恢复至 e8，以确保后续点积迭代继续按 INT8 宽度解析输入。相比之下，自定义方案仅需单条 vdot.vv 指令即可完成完全相同的 128 位输出。上述两套基准程序的自动生成逻辑位于 experiments/throughput/study.py。

3 独立点积数量与实测结果

为探明超标量乱序后端在不同指令级并行度下的真实吞吐收益，本实验将单轮循环体内的独立点积展开数量依次设为 1、2、4、8、16，并在每种展开度下横向对比标准 RVV 组合、自定义 vdot 以及空循环基准。同时，实验还专门设置了 1 组单点积原址串行依赖

链参照组。每组测试分别覆盖循环次数 N=0、64、256、1024，共计 72 个独立程序，每个程序各重复测量 3 次：



每轮独立点积数量	标准 RVV（周期/点积）	自定义 vdot（周期/点积）	同条件硬件周期比
1	14.004032	1.528226	9.164
2	7.497984	1.179435	6.357
4	5.089718	1.256048	4.052
8	5.128024	1.044859	4.908
16	5.022429	1.064012	4.720

表 2 所列指标均为包含循环控制开销在内的实测拟合值。实验中，测试源向量在计时起点前已预先装入寄存器，硬件计时窗口完整覆盖主循环迭代、末尾全部目标寄存器转存内存以及 128 位完整结果校验准备。在线性回归模型中，末尾单次转存等固定收尾开销自动归入拟合截距项；通过将不同循环次数 N 拟合得出的边际斜率 b 除以每轮展开的独立点积数量，即可精确求得周期/点积指标。所有参与运算的目标寄存器均在程序末尾接受完整的 128 位全位宽校验。

在原址串行依赖链参照测试中，标准 RVV 组合与自定义 vdot 的实测边际成本分别为 20.991935 周期/点积与 7.008065 周期/点积，对应硬件周期比为 2.995 倍。该串行指标完整反映了包含向量配置、跨迭代结果回写依赖及分支控制在内的单步迭代延迟；而硬件算术单元内部配置的两级流水则描述纯电路从采样到出拍的内部级数，两者分别刻画了完整处理器程序级行为与底层模块级结构。

从独立展开度趋势来看，当每轮循环展开 8 个独立点积时，自定义 vdot 达到了本组实验的最低单点积成本，即 1.044859 周期/点积，展开 16 个时亦稳定在 1.064012 周期/点积，逼近单通道每拍发射 1 条的理论极限。鉴于实际开销随展开度呈现小幅波动，在工程算法移植时，建议综合权衡向量寄存器堆占用压力与外部数据访存装载开销来选定最优展开因子。

4 周期还原与拟合

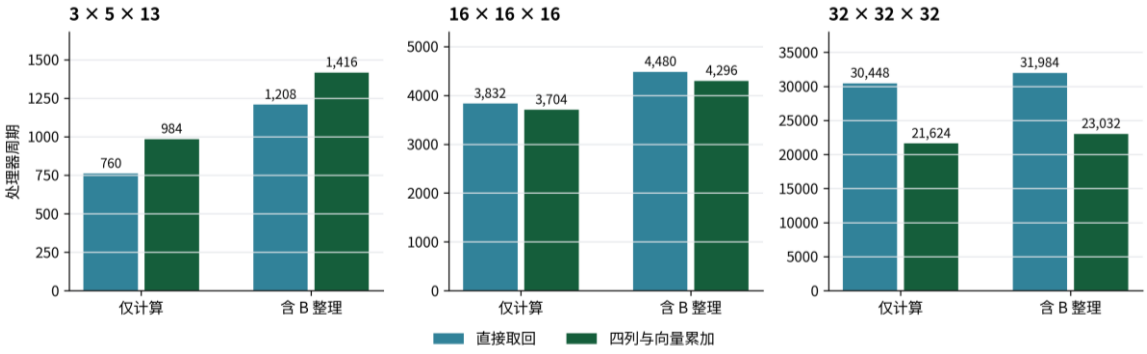
在无打印开销的裸机计时机制下，每轮实测周期差值按 8 周期步进向下取整并编码映射至最终停机地址。设程序停机时的地址为 PC，计时结果着陆区基地址为 LANDING，则量化区间下界为 L=((PC−LANDING)/4)×8，真实硬件周期落在闭区间 [L, L+7] 内。统计脚本先

对每个循环规模 N 下的 3 次重复读数取中位数，再以量化区间中点对四个采样点执行最小二乘线性拟合 C(N)=a+bN，最终将拟合斜率 b 除以每轮点积数得出单点积周期。

实测日志表明，全部 72 个吞吐测试程序各自的 3 次重复运行读数均 100% 一致。在全部 18 组线性回归中，决定系数均满足 $R^2 \geq 0.99$；最大单点拟合残差约为 32.516 周期，反映出除 8 周期地址量化误差外，不同循环规模下分支预测与微架构队列交织也会引入少量非线性波动。此外，扣除空循环基准后的净算术周期估计值已同步保存在归档数据集中供参考，本报告正文统一采用包含真实循环控制开销的实测斜率进行汇报。

5 通用矩阵接口的处理器周期

为进一步检验自定义点积指令在真实算子层面的加速效果，项目组构建了通用矩阵乘法接口基准测试，覆盖 3×5×13、16×16×16 与 32×32×32 三种矩阵规模；针对每种规模，分别对比逐次直接取回与四列共享装载 + 向量寄存器累加两种算子实现策略，并正交评测仅核心计算与包含右矩阵 B 转置整理两种计时口径，合计 12 个测试程序、36 轮整核协同执行全部一次通过：



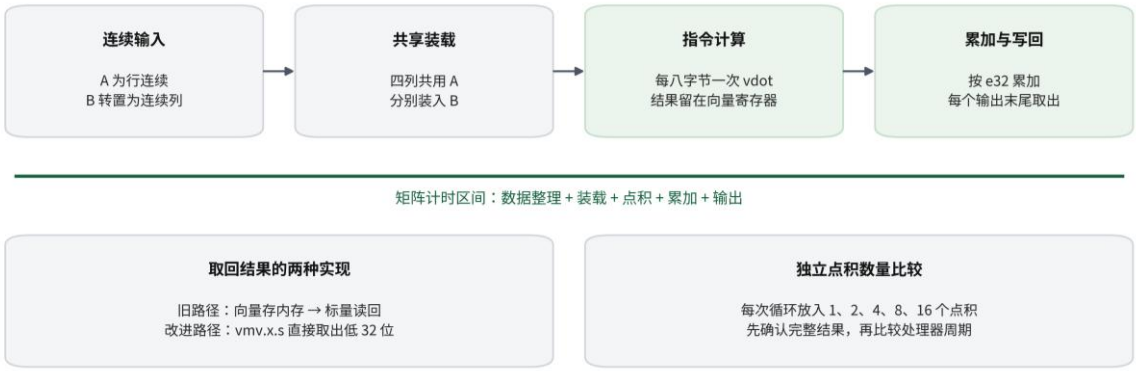
矩阵乘法规模	仅计算：直接取回	仅计算：四列累加	含 B 整理：直接取回	含 B 整理：四列累加
3×5×13	760	984	1208	1416
16×16×16	3832	3704	4480	4296
32×32×32	30448	21624	31984	23032

表 3 中的数值单位均为目标处理器硬件周期，取自每组程序 3 次重复运行的中位数。表中直接给出 8 周期量化区间的下界 L，真实周期在此基础上向上最多偏移 7 个周期；本次实验中每组程序的 3 次量化读数均完全相）。

对比不同矩阵规模的实测数据可以发现：在 32×32×32 方阵下，四列共享装载 + 向量累加方案展现出显著优势，当计入 B 矩阵转置整理时，总周期由 31984 降至 23032，缩减 27.989%，即约 28.0%；在仅计算口径下，总周期由 30448 降至 21624，缩减 28.981%。在 16×16×16 方阵下，四列方案在含整理与仅计算口径下也分别实现了 4.107% 与 3.340% 的周期缩减。相反，在 3×5×13 极小尺寸且列数非 4 倍数的场景下，直接取回方案反而更轻量，含整理仅需 1208 周期，优于四列方案的 1416 周期。这表明在实际算子库工程中，应根据输入矩阵的维度规模自适应分派调用策略。

在计时边界定义上，仅计算口径完整覆盖已转置对齐输入数据的内存加载、点积乘加运算及结果矩阵写回；含整理口径则在此基础上额外纳入了将行主序右矩阵 B 实时转置整理为列连续缓冲区的预处理耗时，裸机启动代码与末尾全矩阵结果比对均排除在计时窗口之外。由于两类计时口径分别由独立的测试镜像运行采集，两者之差仅用于宏观评估数据重排的附加成本；表 3 的核心目标是在统一的通用接口框架内量化对比两种自定义指令调用策略的优劣。

6 接口实现与结果复算



如图 3 所示，在逐次直接取回实现路径中，算子在 e8/m1 模式下执行 vdot.vv 后，立即将 SEW 切换至 e32 并调用 vmv.x.s 把低 32 位点积和直接读入标量寄存器累加，随后切回 e8 继续下一分块，相比早期先将向量存回内存再标量加载的旧路径已大幅简化。而在四列共享装载 + 向量累加改进路径中，内层循环每装载一次左矩阵 A 的 8 字节行切片，即与右矩阵 B 的四列对应切片连续执行 4 次独立点积，分别写入 4 个向量寄存器，并在向量寄存器堆内按 e32 模式执行向量加法累加，直至整个 K 维归约完毕后再一次性写回输出矩阵；针对列数不足 4 的余列及 K 维不足 8 的尾部元素，接口内部均集成了完备的边界补齐与掩码收尾逻辑。

在软件工程封装上，头文件 applications/gemm/include/vdot_gemm.h 定义了统一的连续内存矩阵乘法 API，并通过返回枚举值 C_REFERENCE 或 CUSTOM_VDOT 显式标识当前实际走过的计算后端。在交付前的功能回归中，上述两种矩阵算子实现均已通过 1516 组本机测试向量的交叉核验；同时，基于真实自定义点积指令运行的 6 种代表性矩阵尺寸裸机程序也已全部完成 88 项输出矩阵比对。

工程归档相对路径	归档数据内容与工程用途说明
applications/gemm/	包含 measured_20261026 子目录及算子源码
experiments/throughput/	包含 measured_20261026 子目录
measurements/20261026	保存超算作业的任务状态记录、节点资源配额、输入清单及原始终端日志
performance/figures	存放由统计脚本自动生成的通用矩阵周期对比图与独立点积展开度曲线图

若需在本地对全套 252 轮实测数据进行一键离线复算与完整性校验，可直接运行命令：python -B scripts/check_measurements.py --out ../measured-check-new。当全部数据复核无误时，终端将输出 MEASURED_RESULTS_PASS records=252 groups=84 expected_repeats=3。

本报告内嵌的统计图表均由 performance/build_figures.py 脚本直接读取上述归档结果表自动绘制生成。关于测试程序的重新编译运行及前置工具链准备，请统一查阅项目共用手册第 7、9、10 章。

7 公开参考

RISC-V 向量扩展官方规范：https://docs.riscv.org/reference/isa/unpriv/v-st-ext

XiangShan 开源处理器项目：https://github.com/OpenXiangShan/XiangShan

NEMU 指令集模拟器项目：https://github.com/OpenXiangShan/NEMU

DiffTest 协同验证框架项目：https://github.com/OpenXiangShan/difftest